

Trabalho 2

Rodrigo Malta Esteves

10/03/2021

1. a)
2. b)
3. c)
4. d)
5. e)

```
library(readr)
library(dplyr)
```

```
atend <- read.csv("C:\\Users\\malta\\Desktop\\Pós Graduação\\Introdução ao Aprendizado Estatístico\\Trabalho 2\\atend.csv")
```

Como descrito na introdução, temos que $X1$ é a variável aleatória do número de clientes atendidos por hora e θ é a média do número de clientes atendidos. Essas variáveis seguem as distribuições de probabilidade: $X1 \sim \text{Poisson}(\theta)$ e $\theta \sim \text{Gamma}(\alpha, \lambda)$. Além disso, temos $n = 100$ registros de contagem de atendimentos.

a)

Assumimos uma *priori 1* em que nosso parâmetro $\theta \sim \text{Gamma}(0.001, 0.001)$.

Calculando as medidas de variância, desvio padrão e média desse parâmetro, podemos observar que as medidas de dispersão são muito maiores que a média. Logo, é possível afirmar que, nesse caso, θ tem uma distribuição vaga a priori.

```
#priori 1
theta1 <- rgamma(100000, .001, .001)
theta1 <- as.data.frame(theta1)
theta1 %>%
  summarize(MediaPriori = mean(theta1),
            VarianciaPriori = var(theta1),
            DesvioPriori = sd(theta1))
```

```
##      MediaPriori VarianciaPriori DesvioPriori
## 1      0.9637529          913.9191      30.23109
```

b)

O analista informa que a média de atendimento gira em torno de 5 por hora. Como temos que o parâmetro θ tem distribuição *gama*, sabemos que $E[\theta] = \frac{\alpha}{\lambda}$. Logo, podemos descrever uma relação entre os parâmetros: $\frac{\alpha}{\lambda} = 5 \implies \alpha = 5\lambda$. Também é informado que a $\text{Prob}(\theta > 10) \approx 5\%$.

Associando essas duas informações é possível encontrar uma aproximação para os parâmetros da *priori 2*. Para isso, criamos uma grade de valores de 0 até 5 para λ , uma variável α , respeitando a relação descrita anteriormente, e geramos uma matriz com as probabilidades associadas às distribuições *gama* com esses parâmetros.

Observamos que os parâmetros que mais se aproximam dos 5% de probabilidade são $\alpha = 3.5$ e $\lambda = 0.7$.

```

#Elicitação dos parâmetros da priori 2
lambda<-seq(0,5,0.1)
alpha<-5*lambda
matriz<-cbind(alpha,lambda,1-pgamma(10,shape=alpha,rate=lambda))
matriz #alpha = 3.5 e lambda = 0.7

```

```

##      alpha lambda
## [1,]  0.0    0.0 1.000000e+00
## [2,]  0.5    0.1 1.572992e-01
## [3,]  1.0    0.2 1.353353e-01
## [4,]  1.5    0.3 1.116102e-01
## [5,]  2.0    0.4 9.157819e-02
## [6,]  2.5    0.5 7.523525e-02
## [7,]  3.0    0.6 6.196880e-02
## [8,]  3.5    0.7 5.118135e-02
## [9,]  4.0    0.8 4.238011e-02
## [10,] 4.5    0.9 3.517354e-02
## [11,] 5.0    1.0 2.925269e-02
## [12,] 5.5    1.1 2.437324e-02
## [13,] 6.0    1.2 2.034103e-02
## [14,] 6.5    1.3 1.700084e-02
## [15,] 7.0    1.4 1.422792e-02
## [16,] 7.5    1.5 1.192150e-02
## [17,] 8.0    1.6 9.999781e-03
## [18,] 8.5    1.7 8.396123e-03
## [19,] 9.0    1.8 7.056009e-03
## [20,] 9.5    1.9 5.934709e-03
## [21,] 10.0   2.0 4.995412e-03
## [22,] 10.5   2.1 4.207748e-03
## [23,] 11.0   2.2 3.546600e-03
## [24,] 11.5   2.3 2.991155e-03
## [25,] 12.0   2.4 2.524130e-03
## [26,] 12.5   2.5 2.131152e-03
## [27,] 13.0   2.6 1.800249e-03
## [28,] 13.5   2.7 1.521432e-03
## [29,] 14.0   2.8 1.286361e-03
## [30,] 14.5   2.9 1.088058e-03
## [31,] 15.0   3.0 9.206824e-04
## [32,] 15.5   3.1 7.793409e-04
## [33,] 16.0   3.2 6.599276e-04
## [34,] 16.5   3.3 5.589956e-04
## [35,] 17.0   3.4 4.736489e-04
## [36,] 17.5   3.5 4.014524e-04
## [37,] 18.0   3.6 3.403570e-04
## [38,] 18.5   3.7 2.886376e-04
## [39,] 19.0   3.8 2.448403e-04
## [40,] 19.5   3.9 2.077400e-04
## [41,] 20.0   4.0 1.763029e-04
## [42,] 20.5   4.1 1.496569e-04
## [43,] 21.0   4.2 1.270656e-04
## [44,] 21.5   4.3 1.079069e-04
## [45,] 22.0   4.4 9.165515e-05
## [46,] 22.5   4.5 7.786593e-05

```

```
## [47,] 23.0 4.6 6.616341e-05
## [48,] 23.5 4.7 5.622960e-05
## [49,] 24.0 4.8 4.779540e-05
## [50,] 24.5 4.9 4.063296e-05
## [51,] 25.0 5.0 3.454931e-05
```

c)


Comparando as distribuições das duas priors, podemos ver claramente como a distribuição a *priori 1* reflete uma falta de conhecimento sobre o parâmetro ao ter quase todos os seus valores próximos ao zero para toda grade de valores de θ . Já a *priori 2* explica muito mais sobre o parâmetro, uma vez que atribui probabilidades de forma mais heterogênea entre os valores de θ .

```
#Esperança e Variância da Priori 2
#Teórico
MediaTeoPriori2 <- 3.5/.7 #média teórica
VarianciaTeoPriori2 <- 3.5/ (.7^2) #variância teórica

#Amostral
theta2 <- rgamma(100000,3.5,0.7)
theta2 <- as.data.frame(theta2)
theta2 %>%
  summarize(MediaPriori2 = mean(theta2),
            VarianciaPriori2 = var(theta2),
            MediaTeoPriori2,
            VarianciaTeoPriori2)

##   MediaPriori2 VarianciaPriori2 MediaTeoPriori2 VarianciaTeoPriori2
## 1      5.014959         7.230478              5              7.142857

#Gráfico das priors para uma grade de valores de theta entre 0 e 15
theta<-seq(0,15,0.1)
priori1<-dgamma(theta,shape=0.01, rate=0.01)
priori2<-dgamma(theta,shape=3.5, rate=0.7)
plot(theta, priori2,t="l",col="red") #Priori 2 muito mais informativa
lines(theta, priori1,col="blue")
legend("topright",legend=c("Priori 1","Priori 2"),lty=c(1,1),col=c(4,2))
```



d)

Função de verossimilhança para uma Poisson:

$$l(\theta; \underline{x1}) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{(x1)_i}}{(x1)_i!} = \frac{e^{-n\theta} \theta^{\sum (x1)_i}}{\prod (x1_i!)}.$$

Estimador de máxima verossimilhança para θ :

$$L(\theta; \underline{x1}) = \log(l(\theta; X1)) = \sum (x1)_i \log(\theta) - n\theta - \log(\prod (x1)_i).$$

$$\frac{dL(\theta; \underline{x1})}{d\theta} = \sum \frac{(x1)_i}{\theta} - n = 0.$$

$$\hat{\theta} = \frac{\sum (x1)_i}{n}$$

As distribuições apresentam um resultado esperado. A amostra grande tende a concentrar seus valores mais próximo da máxima verossimilhança, enquanto a amostra pequena apresenta uma dispersão maior.

```
#set.seed(1234)
#amostras
amostra.gr<- atend
amostra.pq<-sample(amostra.gr$X1,10)

#parâmetros
t1 <- sum(amostra.gr$X1)
n1 <- length(amostra.gr$X1)
t2 <- sum(amostra.pq)
```


```

n2 <- length(amostra.pq)

#estimadores de máxima verossimilhança
mv1 <- t1/n1
mv2 <- t2/n2

theta<-seq(0,10,0.01)
vero.gr<-exp(-n1*theta)*theta^t1
vero.pq<-exp(-n2*theta)*theta^t2
plot(theta,vero.gr/max(vero.gr),t="l",col="red")
lines(theta,vero.pq/max(vero.pq),col="blue")
legend("topright",legend=c("Amostra grande","Amostra pequena"),lty=c(1,1),col=c(2,4))

```



e)

Sabemos que se Y_1, \dots, Y_n independentes e identicamente distribuídos seguem uma distribuição $Poisson(\theta)$ e $\theta \sim Gama(\alpha, \beta)$, então, a posteriori, temos que $\theta|\underline{y} \sim Gama(\alpha + \sum y_i, \beta + n)$.

Observamos aqui 4 posteriores possíveis (consideramos $t1$ como o somatório dos valores da amostra grande, $t2$ como o somatório dos valores da amostra pequena, n_1 o tamanho da amostra grande e n_2 o tamanho da amostra pequena):

- a) Para priori 1 e amostra pequena: $\theta|\underline{y} \sim Gama(0.001 + t2, 0.001 + n_2)$
- b) Para priori 2 e amostra pequena: $\theta|\underline{y} \sim Gama(3.5 + t2, 0.7 + n_2)$


- c) Para priori 1 e amostra grande: $\theta|y \sim Gama(0.001 + t1, 0.001 + n_1)$
- d) Para priori 2 e amostra grande: $\theta|y \sim Gama(3.5 + t1, 0.7 + n_1)$

Podemos perceber que para as posteriores com a uma amostra grande a informação vinda dos dados, representada pela verossimilhança, dominará a distribuição. Essa característica fica bem clara dada a concentração de ambas as posteriores em torno do estimador de máxima verossimilhança.

Para as posteriores com uma amostra pequena, observamos uma dispersão maior para os valores de θ . Percebemos também que como a priori 1 é pouco informativa a sua posteriori será muito semelhante à distribuição dos dados, ou seja, a própria curva de verossimilhança. Já a segunda posteriori terá os seus valores levados um pouco mais para a direita, uma vez que a priori 2 é mais informativa e tem uma média maior.

```
theta<-seq(0,15,0.1)
poster.1.pq <- dgamma(theta,0.001+t2, 0.001+n2)
poster.2.pq <- dgamma(theta,3.5+t2, 0.7 + n2)
poster.1.gr <- dgamma(theta,0.001+t1, 0.001+n1)
poster.2.gr <- dgamma(theta,3.5+t1, 0.7 + n1)

##Preparação de uma janela gráfica particionada em duas linhas e duas colunas, para acomodar os 4 gráficos
#par(mfrow=c(1,2))
#Posteriori para theta sob amostra pequena e priori 1:
plot(theta,poster.1.pq,type="l",ylab="n=10")
#Posteriori para theta sob amostra pequena e priori 2:
lines(theta,poster.2.pq,type="l",ylab="n=10",col=2)
abline(v=mv2,lty=2,col="darkgreen")
legend("topright",legend=c("Posterior 1 PQ","Posterior 2 PQ","EMV"),lty=c(1,1,2),col=c(1,2,"darkgreen"))
```



```

#Posteriori para theta sob amostra grande e priori 1:
plot(theta,poster.1.gr,type="l",ylab="n=100")
#Posteriori para theta sob amostra grande e priori 2:
lines(theta,poster.2.gr,type="l",ylab="n=100",col=2)
abline(v=mv1,lty=2,col="darkgreen")
legend("topright",legend=c("Posterior 1 GR","Posterior 2 GR","EMV"),lty=c(1,1,2),col=c(1,2,"darkgreen"))

```

