Atividade 3 - Mineração de Dados

Rodrigo Malta Esteves 30/03/2021

```
library(readr) #Ler os dados
library(factoextra) #Análise de componentes principais
library(stringr) #Manipulação de strings
library("reshape2") #
library(tidyverse) #
library(dendextend) #Pacote para fazer dendograma
library(cluster)
```

```
nutr <- read_csv("C:\\Users\\malta\\Desktop\\Pós Graduação\\Mineração de Dados\\Trabalhos\\Atividade 3\\
nutr2 <- nutr[,c(2,4:8)]
attach(nutr2)</pre>
```

Questão 1

```
## Manipulando os dados
nutr3 <- nutr2[,-1]  # retirando a coluna de nomes
nomes <- nutr2[,1]  # pegando a primeira palaura
nutr3 <- as.data.frame(nutr3)
nomes <- as.data.frame(nomes)

## Nomeando as linhas do data frame
row.names(nutr3) <- nomes$Country
head(nutr3)</pre>
```

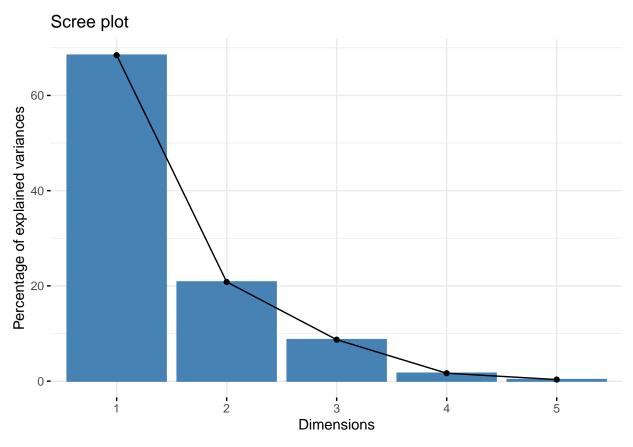
```
Severe. Wasting Wasting Overweight Stunting
##
## LEBANON
                                  2.250000 5.100000 18.750000 16.85000
## ETHIOPIA
                                  3.016667 9.957143 2.750000 47.84286
## GUINEA
                                  3.242857 9.425000 4.333333 34.23750
## NIGER (THE)
                                  4.330000 15.936364 1.520000 46.00000
                                  5.400000 10.125000 12.466667 39.12500
## COMOROS (THE)
## REPUBLIC OF MOLDOVA (THE)
                                  1.450000 3.850000 6.900000 8.55000
##
                            Underweight
                                3.85000
## LEBANON
## ETHIOPIA
                               31.05714
## GUINEA
                               19.26250
## NIGER (THE)
                               38.26364
## COMOROS (THE)
                               19.57500
## REPUBLIC OF MOLDOVA (THE)
                               2.70000
```

```
## Análise de componentes principais
acp <- prcomp(nutr3,scale=TRUE) # scale padroniza as variáveis</pre>
```

i) Porcentagem da variabilidade explicada por cada componente.

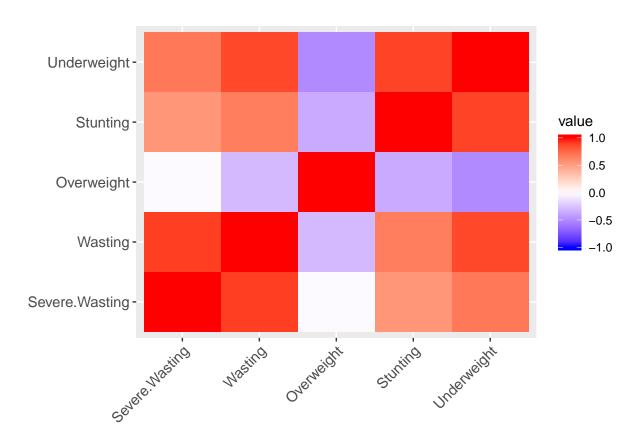
Verificamos que as duas primeiras componentes foram suficientes para explicar 89.29% da variabilidade total. Nesse estudo, a primeira componente principal (CP1) representa 68.45% do total da variância e inclui as variáveis com os coeficientes de maior peso (autovetores) e contribuições (acp\$rotations), representada por: Underweight(-0.7854,52.44%) e Stunting(-0.5745,46.31%). Já a segunda componente (CP2), a variável de maior autovetor e contribuição foi Overweight(0.6244,82.32%).

```
# Proporção da variabilidade explicada por cada componente
summary(acp)
## Importance of components:
##
                          PC1
                                 PC2
                                        PC3
                                                PC4
                                                       PC5
## Standard deviation
                        1.8500 1.0207 0.66000 0.28855 0.12922
## Proportion of Variance 0.6845 0.2084 0.08712 0.01665 0.00334
## Cumulative Proportion 0.6845 0.8929 0.98001 0.99666 1.00000
acp
## Standard deviations (1, .., p=5):
## [1] 1.8500351 1.0206917 0.6599988 0.2885523 0.1292196
##
## Rotation (n \times k) = (5 \times 5):
##
                       PC1
                                 PC2
                                           PC3
                                                     PC4
                                                                 PC5
## Severe.Wasting 0.4403885 -0.4956999 0.3359607 -0.5951612 -0.30537368
                 0.5060601 - 0.2126939 \quad 0.3532750 \quad 0.4315907 \quad 0.62256783
## Wasting
                -0.2456605 \ -0.8232197 \ -0.4316778 \ \ 0.2737154 \ -0.02635352
## Overweight
## Stunting
                 ## Underweight
                 ## Scree plot
fviz_eig(acp) # Proporção da variabilidade explicada por cada componente
```



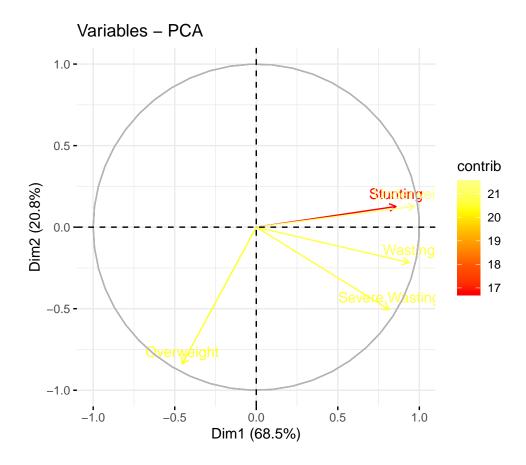
```
# Matriz de covariância
Sigma <- cov(nutr3)</pre>
# Autovalores e autovetores
e <- eigen(Sigma)
Gamma <- e$vectors
                     # autovetores
Lambda <- e$values
                     # autovalores
## eigen() decomposition
## $values
## [1] 350.3236312 29.0168386 19.0649359
                                             2.3571660
                                                          0.2244724
##
## $vectors
                           [,2]
                                       [,3]
##
               [,1]
                                                  [,4]
## [1,] -0.05840832 -0.04556953 -0.2527578 0.4477484 0.85448627
## [2,] -0.18383546 -0.29684403 -0.4982167 0.6170583 -0.49910643
## [3,] 0.12513245 0.62448221 -0.7216572 -0.2695410 -0.03037122
## [4,] -0.78549250  0.52994207  0.2544577  0.1872986 -0.04830570
## [5,] -0.57457497 -0.48886645 -0.3199309 -0.5576982 0.13225027
# Reshape
corrm <- cor(nutr3)</pre>
corrm2 <- melt(corrm)</pre>
```

```
# Visualização da matriz de correlação
ggplot(corrm2,aes(x=Var1,y=Var2,fill=value)) + geom_tile() +
labs(x="",y="") + theme(axis.text.x=element_text(angle=45,hjust=1,size=11),axis.text.y=element_text(s
scale_fill_gradient2(low="blue",high="red",mid="white",limit=c(-1,1))
```

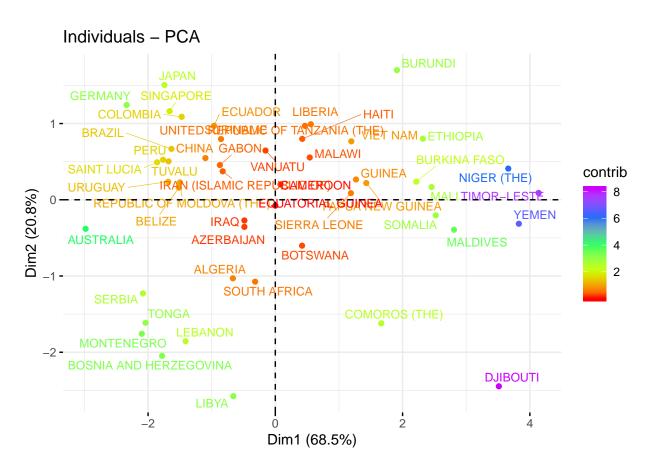


ii) Variáveis, países e biplot.

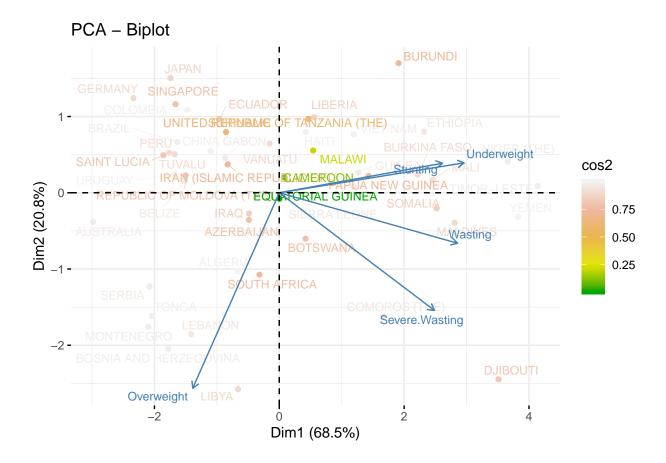
Variables - PCA -> relação entre as componentes principais e as variáveis originais. fviz_pca_var(acp,col.var="contrib",gradient.cols=heat.colors(5))



Individuals - PCA -> elementos do banco de dados em termos das componentes principais.
fviz_pca_ind(acp,repel=TRUE,col.ind="contrib",gradient.cols=rainbow(5),labelsize = 3)



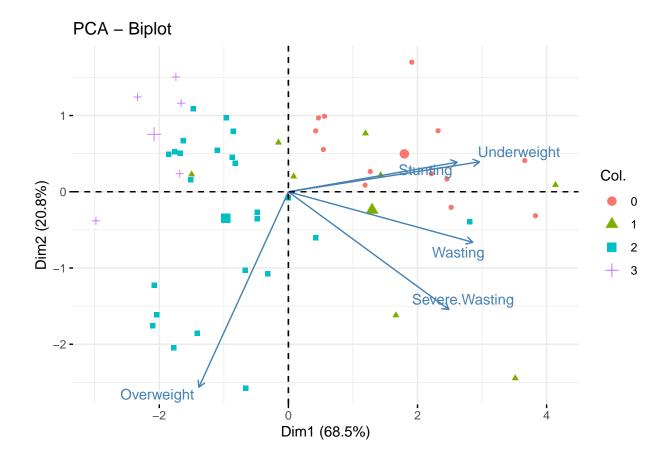
PCA - Biplot -> combinação dos dois plots anteriores
fviz_pca_biplot(acp,repel=TRUE,col.ind="cos2",gradient.cols=terrain.colors(5),labelsize = 3)



Questão 2

Países com rendas "0" e "1" tem uma tendência muito maior a ter problemas relacionadas a subnutrição uma vez que estão localizados nos primeiro e quarto quadrantes do biplot. Os países afetados por problema de sobrepeso estão mais relacionados com rendas maiores "2" e "3".

```
# Biplot dos paises pela renda
fviz_pca_biplot(acp,col.ind=as.factor(nutr$Income.Classification), repel=TRUE,geom="point")
```



Questão 3

Nesse caso, podemos usar para definir os clusters a variável referente a renda (Income.Classification)

```
dist_customers <- dist(nutr3)
hc_customers <- hclust(dist_customers)

#Calculate the mean for each category
#segment_customers %>%
# group_by(cluster) %>%
# summarise_all(list(mean))

hc_players <- hclust(dist_customers,method="complete")
dend_players <- as.dendrogram(hc_players)

clust_customers2 <- cutree(hc_customers,k=2)
segment_customers2 <- mutate(nutr3, cluster = clust_customers2)
count(segment_customers2,cluster)</pre>
```

```
## # A tibble: 2 x 2
## cluster n
## <int> <int>
## 1 1 31
## 2 2 19
```

```
dend_color_2 <- color_branches(dend_players,k=2)
dend_color_2 <- set(dend_color_2, "labels_cex", .5)
plot(dend_color_2)</pre>
```

```
clust_customers3 <- cutree(hc_customers,k=3)
segment_customers3 <- mutate(nutr3, cluster = clust_customers3)
count(segment_customers3,cluster)</pre>
```

```
dend_color_3 <- color_branches(dend_players,k=3)
dend_color_3 <- set(dend_color_3, "labels_cex", .5)
plot(dend_color_3)</pre>
```

```
AUSTRALLA

AUSTRALLA

SERBIA

SSINGA-POR

SURVINAMI

SINGA-POR

SURVINAMI

SINGA-POR

SURVINAMI

SURVINAMI

SELIZE

COLOMBIA

CARREROLA

CAMEROLA

CAMEROLA

CAMEROLA

COLOMBIA

ACERRALIAN

ACERRALIAN

ACERRALIAN

COLOMBIA

CAMEROLA

COLOMBIA

CAMEROLA

CAMEROLA

COLOMBIA

CAMEROLA

COLOMBIA

CAMEROLA

COLOMBIA

CAMEROLA

COLOMBIA

CAMEROLA

COLOMBIA

CAMEROLA

COLOMBIA

COLOMBIA

ACERRALIAN

COLOMBIA

COMOROGO (THE)

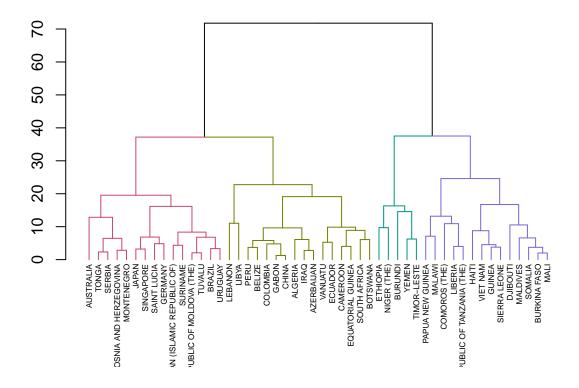
VIETNAMI

VIETN
```

```
clust_customers4 <- cutree(hc_customers,k=4)
segment_customers4 <- mutate(nutr3, cluster = clust_customers4)
count(segment_customers4,cluster)</pre>
```

```
## # A tibble: 4 x 2
##
     cluster
##
       <int> <int>
## 1
            1
                 16
## 2
            2
                   5
            3
## 3
                  14
## 4
            4
                  15
```

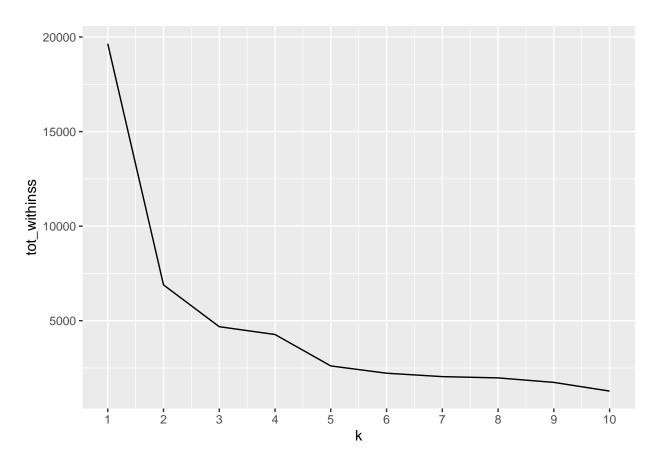
```
dend_color_4 <- color_branches(dend_players,k=4)
dend_color_4 <- set(dend_color_4, "labels_cex", .5)
plot(dend_color_4)</pre>
```



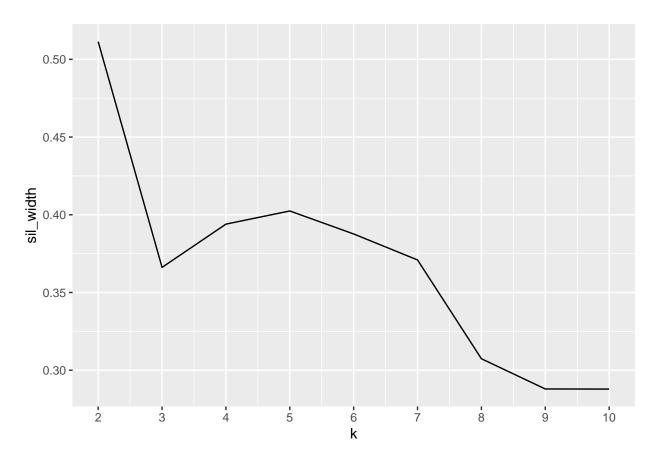
4.

A análise do "cotovelo" aponta para k=2 clusters como a melhor escolha possível, concordando com a análise de componentes principais. No entanto, assim como no dendrograma, o número de clusters ideal para ser usado dependerá de como os dados serão usados para análises posteriores.

```
# Elbow Analysis
# Rodando modelos variando os k's
tot_withinss <- map_dbl(1:10, function(k){
    model <- kmeans(x = nutr3, centers = k)
    model$tot.withinss
})
# Gerando um data frame com os k
elbow_df <- data.frame(
    k = 1:10,
    tot_withinss = tot_withinss
)
# Plot do "cotovelo"
ggplot(elbow_df, aes(x = k, y = tot_withinss)) +
    geom_line() +
    scale_x_continuous(breaks = 1:10)</pre>
```

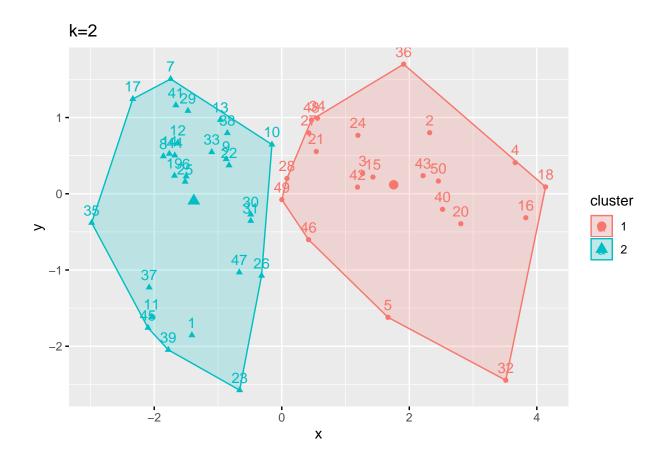


```
# Average Silhouette Widths
# Use map_dbl to run many models with varying value of k
sil_width <- map_dbl(2:10, function(k){
   model <- pam(nutr3, k = k)
   model$silinfo$avg.width
})
# Generate a data frame containing both k and sil_width
sil_df <- data.frame(
   k = 2:10,
   sil_width = sil_width
)
# Plot the relationship between k and sil_width
ggplot(sil_df, aes(x = k, y = sil_width)) +
   geom_line() +
   scale_x_continuous(breaks = 2:10)</pre>
```

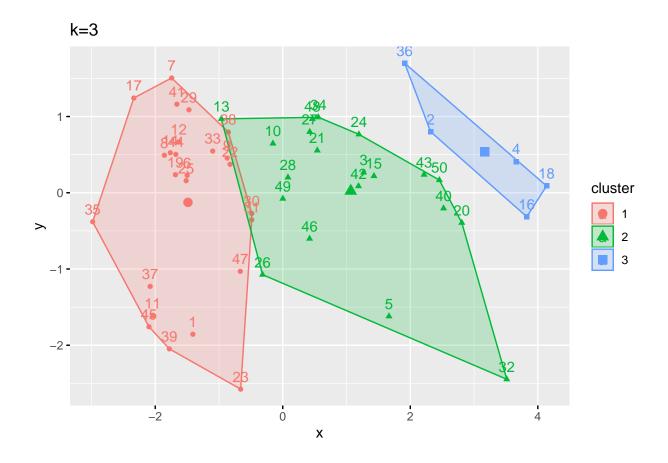


```
k2 <- kmeans(nutr[,4:8],2)
k3 <- kmeans(nutr[,4:8],3)
k4 <- kmeans(nutr[,4:8],4)

fviz_cluster(k2,data=nutr[,4:8]) + labs(x="x",y="y",title="k=2")</pre>
```



fviz_cluster(k3,data=nutr[,4:8]) + labs(x="x",y="y",title="k=3")



fviz_cluster(k4,data=nutr[,4:8]) + labs(x="x",y="y",title="k=4")

